evangelionPL

Manual de usuario y manual técnico. Fases 1, 2 y 3

Juan Pablo Orjuela Rojas
Lenguajes de Programación y Transducción
Ciencias de la Computación e Inteligencia Artificial
Universidad Sergio Arboleda, 2026-2

1. Qué es evangelionPL

evangelionPL es un lenguaje de dominio específico para trabajar con tablas de datos: cargar un CSV, escoger columnas, filtrar filas, crear columnas calculadas, agrupar, sacar estadísticas y guardar el resultado, y además graficar y entrenar modelos de aprendizaje automático. Las instrucciones se llaman como cosas de Neon Genesis Evangelion: los datos entran por el `ENTRY_PLUG`, el `AT_FIELD` deja pasar únicamente las filas que cumplen una condición y las `MAGI` hacen los cálculos. Para que programar sea más fácil, cada instrucción también se puede escribir con una palabra en español (`cargar`, `filtrar`, `resumir`…); las dos formas hacen lo mismo y se pueden mezclar.

La idea central es el flujo: se parte de una tabla y se le encadenan etapas con `|>`. Cada etapa recibe una tabla y entrega otra nueva, así que el programa se lee de arriba hacia abajo como una lista de pasos. Alrededor del flujo hay lo que tiene cualquier lenguaje: variables, condicionales, ciclos, funciones, listas y diccionarios.

Está hecho con ANTLR4 y Python, sin librerías ya hechas para el trabajo de fondo. Los datos los maneja una librería propia de tablas en vez de pandas; las gráficas se dibujan píxel por píxel y el PNG se arma desde cero en vez de usar Matplotlib; las matemáticas, las matrices y los modelos (regresión lineal, árboles de decisión, perceptrón, red neuronal, k vecinos y k-medias) están escritos a mano, sin `math`, NumPy ni scikit-learn. Este documento sirve como manual de usuario (secciones 1, 2, 6, 10, 11 y 12) y como manual técnico (3 a 5, 7 a 9 y 13).

Fase	Qué pide el curso	Estado
1	Especificación del lenguaje, gramática, lexer y parser, árbol de análisis y errores léxicos y sintácticos.	Completa
2	Visitor, tabla de símbolos, ejecución sobre datos, agregaciones, exportar a CSV y errores semánticos.	Completa
3	Gráficas con títulos, ejes, leyendas y archivos de salida, ejecución desde consola, caso de estudio con datos reales y pruebas de regresión.	Completa
3	Lo que pidió el profesor en clase: variables, condicionales, ciclos, estructuras `[ ]` y `{ }`, funciones, matemáticas y matrices propias, y aprendizaje automático propio (predicción, clasificación y agrupamiento).	Completa

Un primer programa

```
# Primer cargar las pruebas y ver las cinco mejores
NERV "Primera prueba de sincronizacion"

pruebas = ENTRY_PLUG "datos/pruebas_sincronizacion.csv"

mejores = pruebas
    |> TARGET [fecha, piloto, unidad, sincronizacion]
    |> AT_FIELD donde sincronizacion >= 60 y piloto != "Kaworu"
    |> FORMATION por [sincronizacion desc]
    |> BATTERY 5

MONITOR mejores
```

Al ejecutarlo con `python run.py ejemplos/01_primera_prueba.eva` sale la tabla y, como todo estuvo bien, el EVA-01 felicita:

```
MONITOR mejores (5 filas x 4 columnas)
fecha       piloto  unidad  sincronizacion
2015-10-19  Shinji  EVA-01           93.50
2015-07-20  Asuka   EVA-02           92.70
2015-08-03  Asuka   EVA-02           86.60
2015-10-05  Shinji  EVA-01           80.10
2015-09-07  Rei     EVA-00           77.90
```



```
  ¡Felicidades, Shinji! (omedetou!)
  Sincronización con el EVA-01 al 100 %: 01_primera_prueba.eva corrió sin errores.

    Operación : Primera prueba de sincronizacion
    Tokens    : 42
    Variables : pruebas, mejores
```

El mismo tipo de programa escrito con las palabras en español:

```
programa "Resumen por piloto"

pruebas = cargar "datos/pruebas_sincronizacion.csv"
    |> quitar faltantes [sincronizacion]
    |> filtrar donde sincronizacion >= 60

resumen = pruebas
    |> agrupar por [piloto]
    |> resumir pruebas = contar(), promedio = media(sincronizacion)
    |> ordenar por [promedio desc]

mostrar resumen
guardar resumen como "salidas/resumen.csv"
```

2. Catálogo de instrucciones

Cada instrucción tiene dos nombres que valen igual: el de la serie, en mayúscula, y uno en español, en minúscula. Los conectores (`donde`, `por`, `como`, `con`, `de`) van siempre en español. Los ciclos y las funciones solo tienen nombre en español. La última columna cuenta por qué cada instrucción se llama así.

Evangelion	Español	Qué hace	Por qué ese nombre
`NERV "título"`	`programa "título"`	Le pone nombre a la operación. Es opcional y va en la primera línea.	NERV es la organización que dirige todo.
`ENTRY_PLUG "archivo.csv"`	`cargar "archivo.csv"`	Carga un archivo CSV como tabla.	Es la cápsula por donde el piloto entra al EVA; aquí es por donde entran los datos.
`TARGET [a, b]`	`seleccionar [a, b]`	Deja solo las columnas de la lista.	Fijar el blanco antes de disparar.
`AT_FIELD donde condición`	`filtrar donde condición`	Deja pasar solo las filas que cumplen la condición.	El campo AT es la barrera que no deja pasar casi nada.
`SYNC col = expresión`	`crear col = expresión`	Crea una columna calculada (o varias, separadas por coma).	La sincronización entre piloto y EVA.
`CODENAME [vieja -> nueva]`	`renombrar [vieja -> nueva]`	Les cambia el nombre a las columnas.	Los nombres clave.
`FORMATION por [col desc]`	`ordenar por [col desc]`	Ordena las filas; cada columna puede ir asc o desc.	La formación en la que salen las unidades.
`EJECT duplicados | faltantes | columnas`	`quitar ...`	Saca filas repetidas, filas con vacíos o columnas completas.	La eyección de la cápsula.
`DUMMY_PLUG col = valor`	`rellenar col = valor`	Rellena los vacíos de una columna.	El dummy plug reemplaza al piloto cuando falta.
`EQUIP col -> tipo`	`convertir col -> tipo`	Convierte la columna a entero, real, texto o booleano.	Los equipos (tipo B, tipo D) que le cambian al EVA.
`SQUAD por [a, b]`	`agrupar por [a, b]`	Arma los grupos. Después siempre va MAGI.	El escuadrón.
`MAGI n = contar(), m = media(col)`	`resumir ...`	Calcula un resumen por grupo, o de toda la tabla si no hay grupos.	Las supercomputadoras que hacen todos los cálculos de NERV.
`BATTERY n`	`limitar n`	Deja las primeras n filas.	La batería interna, que dura poquito.

Evangelion	Español	Qué hace	Por qué ese nombre
`DIAGNOSTIC`	`diagnosticar`	Estadísticas de cada columna: válidos, faltantes, distintos, media, desviación, mínimo y máximo.	El chequeo de la unidad.
`PROFECIA obj por [a, b] vecinos k`	`pronosticar ...`	Predice la columna obj de cada fila con sus k filas más parecidas (k vecinos), sin contarse a sí misma, y agrega la columna obj_prediccion.	Las profecías de los Manuscritos del Mar Muerto.
`MONITOR flujo`	`mostrar flujo`	Muestra una tabla, un valor, una lista o una matriz en la terminal.	Las pantallas del centro de mando.
`SEELE flujo como "archivo.csv"`	`guardar flujo como "..."`	Guarda una tabla en un CSV.	El comité al que NERV le entrega informes.
`PATTERN_BLUE c { } PATTERN_ORANGE { }`	`si c { } sino si c2 { } sino { }`	Condicional: ejecuta el primer bloque cuya condición se cumpla.	Patrón azul es ángel confirmado; patrón naranja, sin identificar.
`HOLOGRAM tipo de tabla { }`	`graficar tipo de tabla { }`	Dibuja una gráfica (barras, lineas, histograma, dispersion o caja) y la guarda en PNG o SVG.	Los hologramas de las reuniones de SEELE.
—	`mientras c { }`	Repite el bloque mientras la condición sea verdadera.	—
—	`para i desde a hasta b { }`	Repite el bloque con un contador que va de a a b, los dos incluidos.	—
—	`para x en coleccion { }`	Recorre una lista, un texto, las claves de un diccionario o las filas de una tabla.	—
—	`funcion f(a, b) { retornar ... }`	Define una función con parámetros que devuelve un resultado.	—

Funciones

Función	Uso
`suma media mediana desviacion`	Agregaciones sobre una columna numérica.
`minimo maximo contar`	Agregaciones sobre cualquier columna. `contar()` sin columna cuenta filas.
`filas(tabla)`	Cuántas filas tiene una tabla.
`redondear(x, n)`, `absoluto(x)`	Para números o columnas numéricas.
`mayusculas(t)`, `minusculas(t)`	Para textos o columnas de texto.

Función	Uso
`reemplazar(t, viejo, nuevo)`	Cambia un pedazo de texto por otro, por ejemplo para traducir los nombres de los países.
`raiz exp ln log sen cos tan tanh piso techo factorial`, constantes `pi` y `e`	Matemáticas propias (sección 8). Sirven con números, listas y columnas.
`biseccion derivada newton mapear`	Reciben una función escrita en el lenguaje: raíces de f, su derivada, o aplicar f a cada elemento de una lista o columna.
`longitud agregar sacar contiene rango ordenada invertida unir claves valores`	Listas y diccionarios. Las agregaciones también reciben listas.
`texto numero columna tabla_de aleatorio semilla`	Conversiones, paso entre tablas y listas, y números al azar con semilla.
`ceros unos identidad transpuesta producto punto determinante inversa resolver forma norma`	Matrices (sección 8).
`regresion arbol reglas perceptron red_neuronal grupos predecir dividir`	Modelos de aprendizaje automático (sección 8).
`r2 error_cuadratico exactitud correlacion`	Métricas para evaluar modelos.

Los tipos de `EQUIP` son entero, real, texto y booleano. Los tipos de `HOLOGRAM` son barras, lineas, histograma, dispersion y caja. Ninguno es palabra reservada: se validan en la fase semántica, para que una columna pueda llamarse, por ejemplo, `texto`.

3. Fase 1: análisis léxico

Toda la gramática está en un solo archivo, `grammar/Eva.g4`: arriba las reglas sintácticas y abajo las léxicas. De ahí ANTLR saca el lexer, que lee el archivo carácter por carácter y entrega tokens. Estas tablas se generan a partir del lexer que produce ANTLR, así que siempre coinciden con la gramática.

Categoría	Tokens (nombre y lexema)
Instrucciones (nombre Evangelion / español)	`NERV / programa`, `ENTRY_PLUG / cargar`, `MONITOR / mostrar`, `SEELE / guardar`, `HOLOGRAM / graficar`, `PATTERN_BLUE / si`, `PATTERN_ORANGE / sino`
Etapas del flujo	`TARGET / seleccionar`, `AT_FIELD / filtrar`, `SYNC / crear`, `CODENAME / renombrar`, `FORMATION / ordenar`, `EJECT / quitar`, `DUMMY_PLUG / rellenar`, `EQUIP / convertir`, `SQUAD / agrupar`, `MAGI / resumir`, `BATTERY / limitar`, `DIAGNOSTIC / diagnosticar`, `PROFECIA / pronosticar`
Funciones y ciclos	`FUNCION funcion`, `RETORNAR retornar`, `MIENTRAS mientras`, `PARA para`, `EN en`, `DESDE desde`, `HASTA hasta`
Conectores	`DONDE donde`, `POR por`, `COMO como`, `CON con`, `DE de`, `ASC asc`, `DESC desc`, `DUPLICADOS duplicados`, `FALTANTES faltantes`, `COLUMNAS columnas`, `VECINOS vecinos`
Lógicos y literales fijos	`Y y`, `O o`, `NO no`, `VERDADERO verdadero`, `FALSO falso`, `NULO nulo`

Categoría	Tokens (nombre y lexema)
Operadores y signos	TUBERIA |>, FLECHA ->, IGUAL_IGUAL ==, DIFERENTE !=, MENOR_IGUAL <=, MAYOR_IGUAL >=, MENOR <, MAYOR >, IGUAL =, MAS +, MENOS -, POR_OP *, DIV /, MODULO %, POTENCIA ^, PAR_IZQ (, PAR_DER), COR_IZQ [, COR_DER], LLAVE_IZQ {, LLAVE_DER }, COMA ,, DOS_PUNTOS :, PUNTO .

Token	Qué reconoce
REAL	dígitos, un punto y más dígitos: 0.75
ENTERO	uno o más dígitos: 42
CADENA	texto entre comillas dobles: "Tokio-3"
CADENA_SIN_CERRAR	comilla que nunca se cierra; se reporta como error léxico
ID	letra o guion bajo seguido de letras, dígitos o guiones bajos: sync_01
ID_ESCAPADO	cualquier texto entre acentos graves: `Unidad EVA`
COMENTARIO	desde # hasta el final de la línea; se descarta
ESPACIOS	espacios, tabulaciones y saltos de línea; se descartan
CARACTER_INVALIDO	cualquier otro carácter; se reporta como error léxico

Decisiones del lexer

Cuando varias reglas léxicas encajan con el texto, ANTLR decide con dos criterios, en este orden: primero gana la que reconoce el pedazo más largo, y si dos reconocen exactamente el mismo texto, gana la que está escrita más arriba en la gramática. Por eso las palabras reservadas se declaran antes que `ID`: `MAGI` encaja con las dos reglas y sale como instrucción. En cambio `MAGI_2` es más largo como `ID` y sale como nombre. Si `ID` estuviera primero, ninguna instrucción se reconocería nunca. Las reservadas distinguen mayúsculas: `magi` es un nombre cualquiera.

Los dos nombres de cada instrucción son un solo token: la regla léxica tiene dos alternativas, por ejemplo `MONITOR : 'MONITOR' | 'mostrar' ;`. Así el parser y el Visitor no cambian según cómo se escriba, y las palabras en español (`si`, `para`, `en`, `mostrar`…) también quedan reservadas.

`REAL` va antes que `ENTERO` para que `3.5` no se parta en tres tokens. Los comentarios y los espacios se descartan con `-> skip` y el parser nunca los ve.

Las palabras `y`, `o` y `no` son operadores, así que no sirven como nombres de variable. Para una columna que se llame así, o que tenga espacios, se usan acentos graves: `` `Unidad EVA` ``.

Hay dos tokens que existen solo para atrapar errores: `CARACTER_INVALIDO` y `CADENA_SIN_CERRAR`. Con ellos el lexer nunca se queda atascado y el error se reporta con la línea y la columna exactas.

Los tokens de un programa

Con `--tokens` se ve lo que entrega el lexer. Estos son los primeros del ejemplo anterior:

```
TOKENS de 01_primera_prueba.eva
   #  LIN:COL  TIPO               LEXEMA
   1  2:1      NERV               NERV
   2  2:6      CADENA             "Primera prueba de sincronizacion"
   3  4:1      ID                 pruebas
   4  4:9      IGUAL              =
   5  4:11     ENTRY_PLUG         ENTRY_PLUG
   6  4:22     CADENA             "datos/pruebas_sincronizacion.csv"
   7  6:1      ID                 mejores
   8  6:9      IGUAL              =
   9  6:11     ID                 pruebas
  10  7:5      TUBERIA            |>
  11  7:8      TARGET             TARGET
  12  7:15     COR_IZQ            [
  13  7:16     ID                 fecha
  14  7:21     COMA               ,
 ...
```

4. Fase 1: análisis sintáctico

Las reglas sintácticas son la primera parte de `grammar/Eva.g4` y de ellas sale el parser. Esta es la gramática en EBNF:

```
(* Gramatica de evangelionPL en EBNF.
   { x } = cero o mas veces, [ x ] = opcional, | = alternativa.
   Cada instruccion tiene dos nombres que valen igual: el de Evangelion y uno en
   espanol, por ejemplo "MONITOR" | "mostrar". Aqui se escribe "MONITOR" / "mostrar". *)

programa       = [ cabecera ] , { sentencia } ;
cabecera       = "NERV" / "programa" , CADENA ;

sentencia      = asignacion | mostrar | guardar | graficar | condicional
               | mientras | para | funcion | retornar | llamada ;
asignacion     = nombre , { "[" , expresion , "]" } , "=" , flujo ;
mostrar        = "MONITOR" / "mostrar" , flujo ;
guardar        = "SEELE" / "guardar" , flujo , "como" , CADENA ;
graficar       = "HOLOGRAM" / "graficar" , ID , "de" , flujo , [ "{" , { opcion } , "}" ] ;
condicional    = "PATTERN_BLUE" / "si" , expresion , bloque ,
                 [ "PATTERN_ORANGE" / "sino" , ( condicional | bloque ) ] ;
mientras       = "mientras" , expresion , bloque ;
para           = "para" , nombre , ( "en" , expresion | "desde" , expresion , "hasta" , expresion ) ,
bloque ;
funcion        = "funcion" , ID , "(" , [ nombre , { "," , nombre } ] , ")" , bloque ;
retornar       = "retornar" , flujo ;
llamada        = ID , "(" , [ expresion , { "," , expresion } ] , ")" ;
bloque         = "{" , { sentencia } , "}" ;

flujo          = fuente , { "|>" , etapa } ;
fuente         = carga | expresion ;
carga          = "ENTRY_PLUG" / "cargar" , CADENA , [ "con" , "{" , { opcion } , "}" ] ;
opcion         = ID , ":" , expresion , [ "," ] ;

etapa          = "TARGET" / "seleccionar" , lista_columnas
               | "AT_FIELD" / "filtrar" , "donde" , expresion
               | "SYNC" / "crear" , columna_nueva , { "," , columna_nueva }
               | "CODENAME" / "renombrar" , "[" , renombre , { "," , renombre } , "]"
               | "FORMATION" / "ordenar" , "por" , "[" , criterio , { "," , criterio } , "]"
               | "EJECT" / "quitar" , "duplicados" , [ lista_columnas ]
               | "EJECT" / "quitar" , "faltantes" , [ lista_columnas ]
               | "EJECT" / "quitar" , "columnas" , lista_columnas
               | "DUMMY_PLUG" / "rellenar" , columna_nueva , { "," , columna_nueva }
               | "EQUIP" / "convertir" , nombre , "->" , ID
               | "SQUAD" / "agrupar" , "por" , lista_columnas
               | "MAGI" / "resumir" , agregacion , { "," , agregacion }
               | "BATTERY" / "limitar" , ENTERO
```

```
                | "DIAGNOSTIC" / "diagnosticar"
                | "PROFECIA" / "pronosticar" , nombre , "por" , lista_columnas , "vecinos" , ENTERO ;

  columna_nueva  = nombre , "=" , expresion ;
  agregacion     = nombre , "=" , ID , "(" , [ nombre ] , ")" ;
  renombre       = nombre , "->" , nombre ;
  criterio       = nombre , [ "asc" | "desc" ] ;
  lista_columnas = "[" , nombre , { "," , nombre } , "]" ;

  (* Expresiones: cada nivel amarra mas fuerte que el anterior *)
  expresion      = disyuncion ;
  disyuncion     = conjuncion , { "o" , conjuncion } ;
  conjuncion     = negacion , { "y" , negacion } ;
  negacion       = "no" , negacion | igualdad ;
  igualdad       = comparacion , { ( "==" | "!=" ) , comparacion } ;
  comparacion    = suma , { ( "<" | "<=" | ">" | ">=" ) , suma } ;
  suma           = termino , { ( "+" | "-" ) , termino } ;
  termino        = unario , { ( "*" | "/" | "%" ) , unario } ;
  unario         = "-" , unario | potencia ;
  potencia       = indexado , [ "^" , unario ] ;
  indexado       = primario , { "[" , expresion , "]" } ;
  primario       = literal
                 | nombre
                 | nombre , "." , nombre
                 | ID , "(" , [ expresion , { "," , expresion } ] , ")"
                 | "[" , [ expresion , { "," , expresion } , [ "," ] ] , "]"
                 | "{" , [ par , { "," , par } , [ "," ] ] , "}"
                 | "(" , expresion , ")" ;
  par            = ( CADENA | nombre ) , ":" , expresion ;

  literal        = ENTERO | REAL | CADENA | "verdadero" | "falso" | "nulo" ;
  nombre         = ID | ID_ESCAPADO ;

  (* Lexico *)
  ENTERO         = digito , { digito } ;
  REAL           = digito , { digito } , "." , digito , { digito } ;
  CADENA         = '"' , { caracter } , '"' ;
  ID             = letra , { letra | digito | "_" } ;
  ID_ESCAPADO    = "`" , caracter , { caracter } , "`" ;
  comentario     = "#" , { caracter } ;
```

Precedencia de los operadores

Nivel	Operadores	Asociatividad
1 (más fuerte)	`( )`, llamadas, `tabla.columna`, listas `[ ]`, diccionarios `{ }` e índices `x[i]`	—
2	`^`	derecha
3	`-` de signo	—
4	`* / %`	izquierda
5	`+ -`	izquierda
6	`< <= > >=`	izquierda
7	`== !=`	izquierda
8	`no`	—
9	`y`	izquierda
10 (más débil)	`o`	izquierda

En la EBNF la precedencia se ve por niveles (suma, término, potencia...). En el archivo `.g4` es una sola regla `expresion` recursiva por la izquierda, y ANTLR saca la precedencia del orden de las alternativas: la que está más arriba amarra más fuerte. Las dos formas describen lo mismo, con una diferencia pequeña: el `.g4` también acepta un `no` como operando (`a == no b`). La potencia es asociativa a la derecha, así que `2 ^ 3 ^ 2` es 2 ^ 9, y `-2 ^ 2` da -4 como en matemáticas.

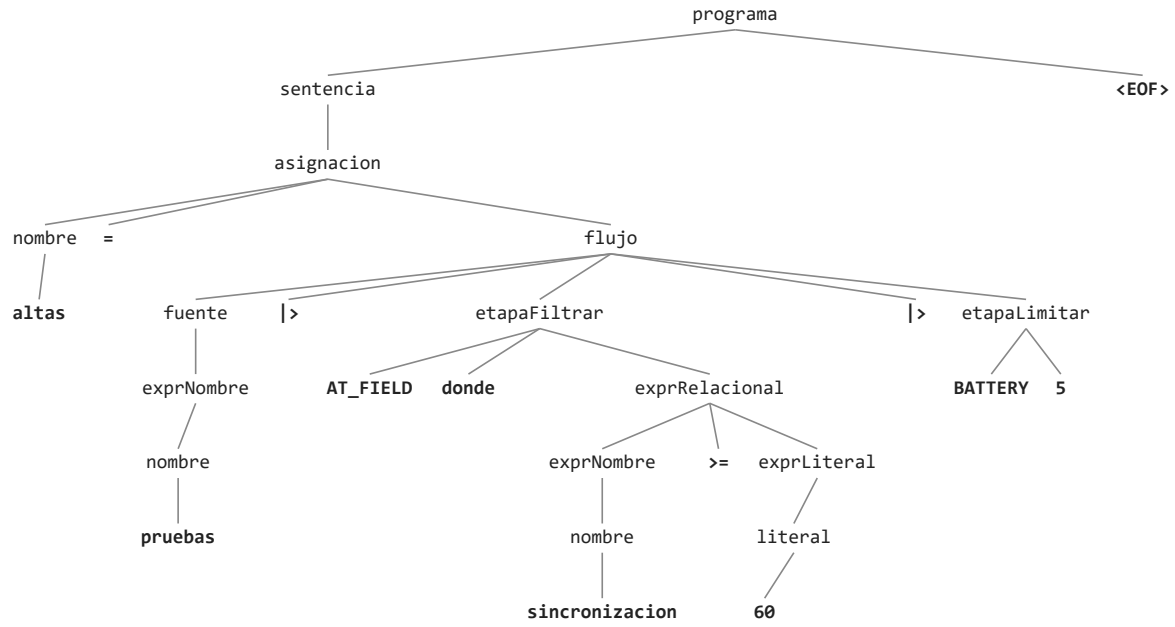
No hay punto y coma. Cada sentencia empieza con una instrucción o con `nombre =`, y con eso el parser sabe dónde termina la anterior. La regla `programa` termina en `EOF` para que no se pueda colar basura al final del archivo.

Árbol de análisis

Para esta línea:

```
altas = pruebas |> AT_FIELD donde sincronizacion >= 60 |> BATTERY 5
```

el parser arma el siguiente árbol. Se ve que la comparación quedó colgando de la etapa `AT_FIELD` y que las dos etapas son hermanas dentro del mismo flujo.



Árbol generado con `python run.py archivo.eva --svg arbol.svg`

El mismo árbol en texto, con `--arbol`:

```
programa
|-- sentencia
|   `-- asignacion
|       |-- nombre
|       |   `-- altas
|       |-- =
|       `-- flujo
|           |-- fuente
|           |   `-- exprNombre
|           |       `-- nombre
|           |           `-- pruebas
|           |-- |>
|           |-- etapaFiltrar
|           |   |-- AT_FIELD
|           |   |-- donde
|           |   `-- exprRelacional
|           |       |-- exprNombre
|           |       |   `-- nombre
|           |       |       `-- sincronizacion
|           |       |-- >=
|           |       `-- exprLiteral
|           |           `-- literal
|           |               `-- 60
|           |-- |>
|           `-- etapaLimitar
|               |-- BATTERY
|               `-- 5
`-- <EOF>
```

Los nodos llevan el nombre de la alternativa (`etapaFiltrar`, `exprRelacional`) y no solo el de la regla. Esas etiquetas son las que después usa el Visitor: ANTLR genera un método `visit` por cada una.

5. Fase 2: semántica y ejecución

Si el programa pasa la fase 1, el árbol se recorre con el patrón Visitor (`src/evangelion/interprete.py`). La clase `Interprete` hereda del `EvaVisitor` que genera ANTLR y tiene un método por cada tipo de nodo: `visitEtapaFiltrar`, `visitExprAditiva`, `visitGuardar`... Cada método revisa que lo que le llegó tenga sentido y después le pide el trabajo a la librería de tablas.

```
programa .eva → lexer → tokens → parser → árbol → Visitor (revisa y ejecuta) → librería de tablas → tablas y CSV
```

Tabla de símbolos

Cada asignación guarda en la tabla de símbolos el nombre, la clase del valor, el valor y la línea donde se definió. Hay un ámbito global y, encima, uno por cada llamada a una función que esté corriendo: dentro de una función los nombres se buscan primero en su ámbito y después en el global, y al salir el ámbito se borra. Los bloques de `si`, `mientras` y `para` no crean ámbito: lo que se asigna adentro sigue existiendo afuera. Con `--simbolos` se imprime al terminar; así queda después del ejemplo 04:

```
TABLA DE SÍMBOLOS
  NOMBRE             CLASE     LÍNEA  VALOR
  pruebas            tabla     4      29 filas x 7 columnas
  asuka              tabla     8      8 filas x 4 columnas
  ultimas            tabla     17     3 filas x 4 columnas
  promedio_total     numero    19     66.6
  promedio_reciente  numero    20     47.9
  alerta             tabla     25     3 filas x 5 columnas
```

Las clases de valor son tabla, numero, texto, booleano, lista, diccionario, funcion y nulo. Una columna suelta (`tabla.columna`) se puede usar dentro de una expresión, pero no guardar en una variable; para eso está `columna(tabla, "nombre")`, que la devuelve como lista.

Reglas semánticas

Sobre	Regla
Variables	Una variable tiene que estar asignada antes de usarse. Se puede volver a asignar. Las constantes pi y e existen siempre, pero una variable con ese nombre las tapa.
Ámbitos	Hay un ámbito global y uno nuevo por cada llamada a una función. Dentro de la función una variable se busca primero en su ámbito y después en el global; lo que se asigna adentro es local.
Funciones	Se llaman con tantos argumentos como parámetros tienen. No pueden llamarse igual que una función del lenguaje. retornar solo va dentro de una función; una función que no retorna devuelve nulo. La recursión llega hasta 100 niveles.
Listas y diccionarios	Las posiciones de una lista van de 0 a largo - 1 (con negativos se cuenta desde el final) y tienen que existir. Las claves de un diccionario son textos o enteros. Las cuentas entre listas van elemento por elemento y piden el mismo largo.
Ciclos	La condición de mientras tiene que dar verdadero o falso; un ciclo que pasa de 1.000.000 de vueltas se detiene con error. desde y hasta van con enteros.
Modelos	regresion, arbol, perceptron, red_neuronal y grupos reciben una tabla sin faltantes en las columnas que usan, y las variables tienen que ser numéricas. El perceptrón separa exactamente dos clases.
Columnas	Toda columna que se nombre en una etapa tiene que existir en la tabla que llega. Si no existe, el error sugiere la que más se parece.
Nombres dentro de una etapa	Primero se busca entre las columnas de la tabla y después entre las variables.
Aritmética	+ - * / % ^ solo aceptan números. El + también pega dos textos. Dividir un valor por cero es un error; dentro de una columna, esa fila queda como faltante.
Comparaciones	< <= > >= comparan número con número o texto con texto. == y != piden la misma clase a los dos lados, salvo que uno sea nulo.
Lógica	y, o, no solo aceptan valores de verdadero/falso.
Condiciones	La condición de AT_FIELD, la de PATTERN_BLUE y la de mientras tienen que dar verdadero o falso.
Etapas	Una etapa solo se aplica a una tabla. Ninguna cambia la tabla original: devuelve una nueva.
Grupos	Después de SQUAD la única etapa permitida es MAGI.
Agregaciones	suma, media, mediana y desviacion piden una columna numérica; minimo, maximo y contar sirven con cualquiera.
Faltantes	Una operación con un faltante da faltante y una comparación da falso. DUMMY_PLUG rellena con un valor de la misma clase que la columna.
Conversión	EQUIP falla si algún valor no encaja en el tipo nuevo. Los vacíos siguen vacíos.

Sobre	Regla
Archivos	ENTRY_PLUG falla si el archivo no existe. SEELE solo recibe tablas y solo escribe .csv.
Gráficas	HOLOGRAM solo recibe tablas. Cada tipo exige sus ejes, los ejes tienen que ser columnas de esa tabla y los que se miden (eje_y, o eje_x en el histograma) tienen que ser numéricos. El archivo tiene que terminar en .png o .svg.

La librería de tablas

Está en `src/evangelion/tablas.py` y no depende de nada externo. El intérprete nunca toca los datos directamente: decide qué hay que hacer y se lo pide a esta librería. Tiene tres partes.

Parte	Qué hace
Archivos CSV	Lee el archivo carácter por carácter: respeta las comillas, acepta cualquier separador y decide si cada columna es de enteros, de reales o de texto. Un campo vacío es un faltante. También escribe el CSV de salida.
`Columna`	Una lista de valores con las operaciones fila por fila (aritmética, comparaciones, y, o, no), las estadísticas y las conversiones de tipo.
`Tabla`	Varias columnas del mismo largo. Sabe seleccionar, filtrar, ordenar por varias columnas, quitar duplicados y faltantes, agrupar, resumir y mostrarse alineada en la terminal.

Algunas decisiones que tocó tomar al escribirla:

Tema	Cómo quedó
Faltantes	Se guardan como None. No cuentan en ninguna estadística.
Media y mediana	La media es la suma entre la cantidad de datos. La mediana es el dato del centro ya ordenados, o el promedio de los dos del centro si la cantidad es par.
Desviación	Es la muestral: la suma de las diferencias al cuadrado se divide entre n - 1 y se saca la raíz. Con un solo dato no se puede calcular y da nulo.
Orden	Se ordena de la última columna a la primera con un ordenamiento estable, y los faltantes van al final.
Grupos	Salen en el orden en que aparecen en la tabla.
Tablas nuevas	Ninguna operación cambia la tabla que recibe; siempre devuelve otra.

Lo único que viene de afuera es el runtime de ANTLR4, que es la herramienta del curso, y pytest, que solo corre las pruebas. Las sugerencias de los errores (*¿Quisiste decir…?*) usan una distancia de Levenshtein escrita a mano.

6. Listas, diccionarios, ciclos y funciones

Una lista se escribe entre corchetes y un diccionario entre llaves. Las posiciones empiezan en 0 y con números negativos se cuenta desde el final. Un elemento se cambia asignándole por su índice,

y un diccionario se puede leer con punto (`d.clave`), igual que una columna.

```
pilotos = ["Shinji", "Asuka", "Rei"]
agregar(pilotos, "Mari")
mostrar pilotos[0]                # Shinji
mostrar pilotos[-1]               # Mari
edades = {"Shinji": 14, Asuka: 14}
edades["Mari"] = 15
mostrar edades.Mari               # 15
mostrar [1, 2, 3] * 2             # [2, 4, 6]: las cuentas van elemento por elemento
```

Por dentro, una lista del lenguaje es una lista de Python y un diccionario es un `dict`; el intérprete revisa antes cada índice, cada clave y cada tipo para dar el error en español. Una matriz es una lista de filas y `mostrar` la imprime fila por fila.

Ciclos

`mientras` repite mientras la condición sea verdadera. `para i desde a hasta b` cuenta de a a b, los dos incluidos, y `para x en ...` recorre una lista, un texto, las claves de un diccionario o las filas de una tabla (cada fila llega como diccionario). Un ciclo que pasa de un millón de vueltas se detiene con un error, para que un error de lógica no deje el programa colgado.

Funciones

Una función se define con `funcion`, recibe parámetros y devuelve un valor con `retornar`, que corta la función en ese momento (también dentro de un ciclo). Puede recibir y devolver cualquier cosa, incluso tablas, así que sirve para encapsular un flujo que se repite. Puede llamarse a sí misma.

```
funcion nivel(toneladas) {
    si toneladas > 3 { retornar "alto" }
    sino si toneladas > 1.5 { retornar "medio" }
    retornar "bajo"
}
datos = datos |> crear contamina = mapear(nivel, co2_per_capita)

funcion f(x) { retornar x ^ 2 - 2 }
mostrar biseccion(f, 0, 2)          # 1.4142, la raíz de f entre 0 y 2
```

En el árbol, `funcion` es una sentencia que guarda en la tabla de símbolos un valor de clase funcion con los nombres de los parámetros y el nodo del bloque. Al llamarla, el Visitor abre un ámbito nuevo, define los parámetros, recorre el bloque y lo cierra al salir; `retornar` lanza una excepción interna que lleva el valor hasta la llamada.

El ejemplo 06

```
# Variables, listas, diccionarios, ciclos y matematicas propias,
# escrito con las palabras en espanol (las de Evangelion tambien sirven)
programa "Listas, ciclos y matematicas"

# --- Listas y diccionarios ---
pilotos = ["Shinji", "Asuka", "Rei"]
agregar(pilotos, "Mari")
mostrar pilotos
mostrar longitud(pilotos)
mostrar pilotos[0]
mostrar pilotos[-1]

edades = {"Shinji": 14, "Asuka": 14, "Rei": 14}
edades["Mari"] = 15
mostrar edades
```

```
mostrar claves(edades)

# --- Ciclos ---
total = 0
para i desde 1 hasta 10 {
    total = total + i
}
mostrar total

para piloto en pilotos {
    si edades[piloto] > 14 {
        mostrar piloto + " es la mayor"
    }
}

# mientras: cuantas veces hay que doblar 1 para pasar de 1000
n = 1
veces = 0
mientras n <= 1000 {
    n = n * 2
    veces = veces + 1
}
mostrar veces

# sino si encadena condiciones
nota = 4.2
si nota >= 4.5 {
    mostrar "excelente"
} sino si nota >= 3 {
    mostrar "aprobado"
} sino {
    mostrar "reprobado"
}

# --- Matematicas propias (sin la libreria math) ---
mostrar raiz(2)
mostrar raiz(27, 3)
mostrar sen(pi / 2)
mostrar redondear(cos(pi), 4)
mostrar ln(e)
mostrar log(1000)
mostrar factorial(10)

# --- Listas como vectores, igual que NumPy ---
precios = [100, 250, 80]
mostrar precios * 1.19
mostrar media(precios)
mostrar [1, 2, 3] + [10, 20, 30]
mostrar raiz([4, 9, 16])
```

```
MONITOR pilotos: ["Shinji", "Asuka", "Rei", "Mari"]

MONITOR: 4

MONITOR: Shinji

MONITOR: Mari

MONITOR edades: {"Shinji": 14, "Asuka": 14, "Rei": 14, "Mari": 15}

MONITOR: ["Shinji", "Asuka", "Rei", "Mari"]

MONITOR total: 55

MONITOR: Mari es la mayor

MONITOR veces: 10

MONITOR: aprobado
```

```
MONITOR: 1.4142

MONITOR: 3.0

MONITOR: 1.0

MONITOR: -1.0

MONITOR: 1.0

MONITOR: 3.0

MONITOR: 3628800

MONITOR: [119.0, 297.5, 95.2]

MONITOR: 143.3333

MONITOR: [11, 22, 33]

MONITOR: [2.0, 3.0, 4.0]
```

7. Fase 3: gráficas

`HOLOGRAM` recibe un flujo, igual que `MONITOR` o `SEELE`, y entre llaves las opciones de la gráfica. Las opciones se evalúan dentro de la tabla, así que `eje_x: pais` nombra la columna `pais` y si está mal escrita sale la sugerencia de siempre.

```
HOLOGRAM barras de ultimo {
    eje_x: pais
    eje_y: co2_mt
    titulo: "Emisiones de CO2 en 2023"
    etiqueta_y: "Millones de toneladas de CO2"
    archivo: "caso_estudio/resultados/g1_barras_emisiones_2023.png"
}
```

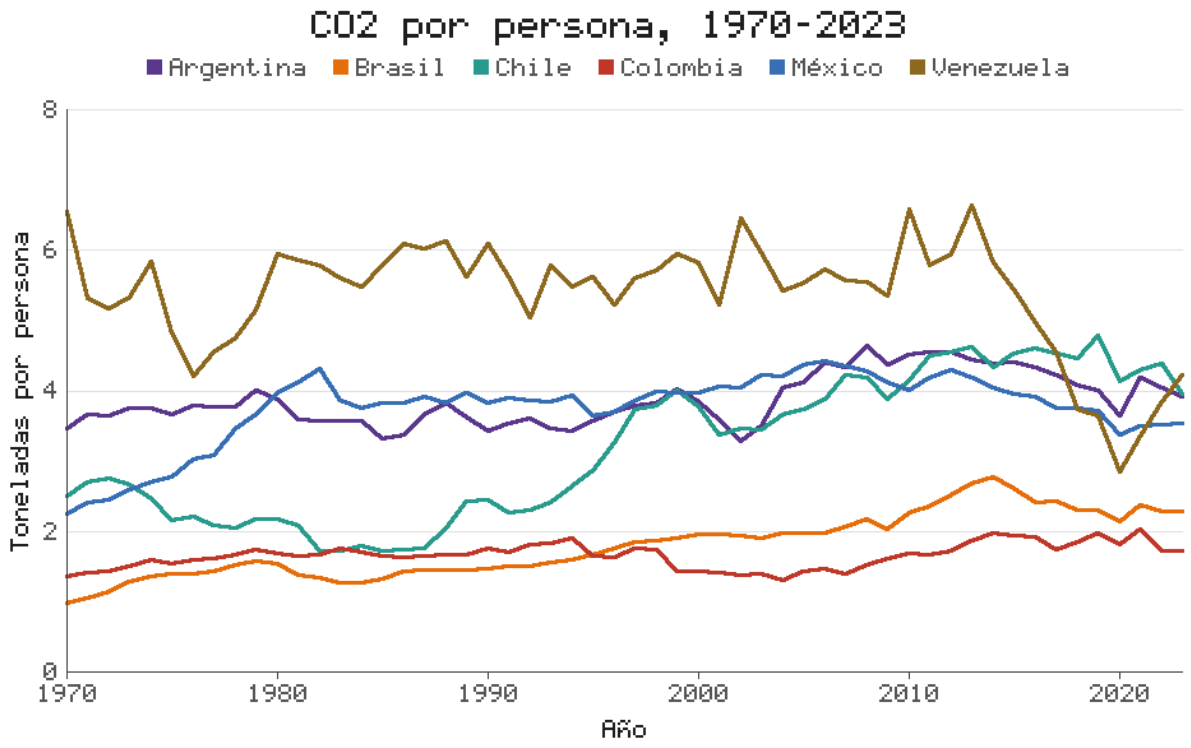
Tipo	Pide	Qué dibuja
`barras`	`eje_x, eje_y`	Una barra por fila con su valor encima. Con serie, barras agrupadas. Si una categoría se repite en la misma serie, sus valores se suman.
`lineas`	`eje_x, eje_y`	Une los puntos en orden de x. Con serie, una línea por grupo.
`histograma`	`eje_x`	Reparte los datos en intervalos del mismo ancho y cuenta cuántos caen en cada uno.
`dispersion`	`eje_x, eje_y`	Un punto por fila; con serie, un color por grupo.
`caja`	`eje_y`	Cuartiles, mediana, bigotes hasta 1,5 veces el rango intercuartílico y los datos atípicos como círculos. Con eje_x, una caja por categoría.

Opciones

Opción	Recibe	Para qué
`eje_x`	columna	Lo que va abajo. En barras y caja son categorías; en lineas puede ser número o texto; en histograma y dispersion es numérico.

Opción	Recibe	Para qué
`eje_y`	columna numérica	Lo que se mide. El histograma no lo usa: cuenta cuántos datos caen en cada intervalo.
`serie`	columna	Separa los datos en grupos de colores con leyenda (barras agrupadas, una línea o una nube de puntos por grupo).
`titulo`	texto	Título arriba de la gráfica.
`etiqueta_x`, `etiqueta_y`	texto	Nombre de cada eje. Si no se dan, se usa el nombre de la columna.
`archivo`	texto	Dónde se guarda. La extensión decide el formato: .png o .svg. Sin esta opción queda en salidas/tipo_n.png.
`color`	texto	Color de la gráfica cuando hay una sola serie: morado, naranja, verde, rojo, azul, amarillo, rosado, gris, negro, cafe o un código #rrggbb.
`intervalos`	entero de 1 a 200	Cuántas barras tiene el histograma. Si no se da, se usa la regla de Sturges.
`ancho, alto`	entero	Tamaño en píxeles. Por defecto 960 x 600.
`leyenda`	verdadero o falso	Muestra u oculta la leyenda de las series.

Las filas a las que les falta algún dato de los ejes se saltan y el mensaje de `HOLOGRAM` dice cuántas se usaron. Las marcas de los ejes son números redondos (pasos de 1, 2, 2,5 o 5 por potencia de 10) y se escriben con coma decimal y punto de miles desde 10.000, para que los años salgan como 1970.



Gráfica de líneas con serie y leyenda (caso de estudio)

Cómo se dibuja por dentro

Está en `src/evangelion/graficas.py` (escalas, ejes, leyenda y los cinco tipos) y en `src/evangelion/lienzo.py` (el dibujo y el formato del archivo). Ninguno usa librerías externas.

Parte	Cómo funciona
Lienzo	Una lista de bytes con un byte por píxel que dice qué color de la paleta lleva. Sabe pintar rectángulos, líneas (algoritmo de Bresenham), círculos y texto.
Letra	Cada carácter es un dibujo de 5 x 7 píxeles hecho a mano en `fuente.py`, con tildes, eñe y signos de apertura. Se agranda multiplicando cada píxel.
Formato PNG	Firma, bloque `IHDR` (tamaño y tipo de color), `PLTE` (la paleta), `IDAT` (los píxeles comprimidos) e `IEND`. Cada bloque lleva su CRC-32, calculado con una tabla propia.
Compresión	DEFLATE con los códigos de Huffman fijos del RFC 1951 y búsqueda de repeticiones LZ77 en dos sitios: el byte anterior (zonas de un color) y el mismo punto de la fila de arriba. Una gráfica de 960 x 600 queda en unos 10-30 KB. Al final va el Adler-32 que pide zlib.
SVG	Un segundo lienzo con los mismos métodos que escribe las figuras como texto. Las gráficas no saben en cuál de los dos dibujan.

Las pruebas abren cada PNG con el `zlib` de Python para comprobar que el compresor propio produce algo que cualquier programa entiende, y comparan el CRC-32 y el Adler-32 con los de la librería estándar. En el lenguaje no se usa ninguno de los dos.

Errores de las gráficas

```
   Error semántico en sem_08_eje_de_texto.eva, línea 3, columna 34
     tipos incompatibles: en la gráfica de histograma el eje_x tiene que ser numérico y 'piloto' es una
columna de texto.
        3 | HOLOGRAM histograma de pruebas { eje_x: piloto }
          |                                  ^
```

8. Matemáticas, matrices y aprendizaje automático

El profesor pidió que los algoritmos fueran propios: nada de `math`, NumPy ni scikit-learn. Hay tres librerías nuevas en `src/evangelion/`, y una prueba revisa que ningún archivo del lenguaje importe `math`, `numpy`, `pandas` ni `matplotlib`.

matematica.py

Función	Cómo se calcula
Raíz	Método de Newton: se mejora una aproximación con $x = ((n - 1)\cdot x + a / x^{n-1}) / n$ hasta que deja de cambiar.
exp, ln, log	exp con la serie de Taylor, partiendo antes el número a la mitad varias veces para que converja rápido; ln escribiendo $x = m \cdot 2^k$ y usando la serie de atanh para m; $\log(x, b) = \ln x / \ln b$.
sen, cos, tan, tanh	Series de Taylor después de llevar el ángulo a $[-\pi, \pi]$; $\tanh = (e^{2x} - 1) / (e^{2x} + 1)$.

Función	Cómo se calcula
piso, techo, factorial	Con enteros, sin el módulo math.
Raíces de funciones	`biseccion(f, a, b)` parte el intervalo a la mitad quedándose con la mitad donde f cambia de signo; `newton(f, x0)` usa x = x - f(x) / f'(x) con la derivada numérica de `derivada(f, x)` = (f(x + h) - f(x - h)) / 2h. Reciben una función escrita en el lenguaje.
Azar	Generador congruencial lineal con semilla, así los resultados se pueden repetir; barajar usa Fisher-Yates.

Las pruebas comparan cada función con la de Python en varios valores y exigen que coincidan al menos en 12 cifras.

matrices.py

Parte	Qué hace
Vectores y matrices	Un vector es una lista de números y una matriz una lista de filas del mismo largo.
Operaciones	Las cuentas entre listas van elemento por elemento, y un número se aplica a todos (como en NumPy). `producto` multiplica matrices (fila por columna); `punto` es el producto punto.
Gauss-Jordan	`determinante`, `inversa` y `resolver(A, b)` usan eliminación de Gauss-Jordan con pivoteo parcial (se escoge el pivote más grande para reducir el error de redondeo).

aprendizaje.py

Cubre lo que pidió el profesor: predicción, clasificación y agrupamiento. Un modelo es un diccionario del lenguaje, así que se puede mostrar o leer por partes (`modelo.coeficientes`, `modelo.perdidas`), y `predecir(modelo, tabla)` le agrega a la tabla la columna `prediccion`. Antes de entrenar, las variables se escalan (media 0, desviación 1) para que una tasa de aprendizaje sirva con cualquier unidad; la regresión devuelve los coeficientes en las unidades originales.

Modelo	Para qué	Cómo aprende	Fuente
`regresion`	Predecir un número	$y = b + w_1x_1 + \dots$ Empieza con pesos al azar y, en cada época, escoge un punto al azar y aplica el *square trick*: $w = w + \text{tasa} \cdot x \cdot (y - \hat{y})$, $b = b + \text{tasa} \cdot (y - \hat{y})$. Es el descenso de gradiente del error cuadrático.	Grokking ML, cap. 3
`arbol`	Clasificar o predecir	En cada nodo prueba cada variable y cada corte y se queda con el de menor índice de Gini ponderado por el tamaño de cada lado ($1 - \Sigma p^2$), o menor varianza si el objetivo es numérico. Se detiene en la profundidad máxima o cuando un lado queda puro.	Grokking ML, cap. 9
`perceptron`	Clasificar en dos	$y = \varphi(\Sigma\, x_i w_i + \theta)$ con φ escalón, lineal, tanh o sigmoide. Con escalón usa el *perceptron trick*; con las demás, descenso de gradiente sobre la función costo (entropía cruzada con sigmoide, error cuadrático con lineal y tanh).	Grokking ML, caps. 5 y 6

Modelo	Para qué	Cómo aprende	Fuente
`red_neuronal`	Clasificar en varias clases	Capa oculta con sigmoide y salida softmax. Retropropagación: la regla de la cadena da la derivada parcial de la pérdida respecto a cada peso, de la salida hacia atrás.	Grokking ML, cap. 10; Grokking AI, cap. 9
`PROFECIA`	Clasificar o predecir	k vecinos más cercanos con distancia euclidiana sobre columnas normalizadas a [0, 1]; cada fila se predice con las demás. La escribió otro integrante del grupo.	—
`grupos`	Agrupar sin respuesta	k-medias: cada fila va al centro más cercano y cada centro se mueve al promedio de su grupo, hasta que nadie cambia. Arranca con k-medias++ y se queda con el mejor de 10 intentos.	—
`dividir`, métricas	Evaluar	Baraja y separa entrenamiento y prueba; `r2`, `error_cuadratico`, `exactitud` y `correlacion` (Pearson).	Grokking ML, caps. 4 y 7

Los libros son *Grokking Machine Learning* (Luis Serrano, 2021) y *Grokking Artificial Intelligence Algorithms* (Rishal Hurbans), que envió el profesor. La regresión sigue el pseudocódigo del capítulo 3 y el árbol calcula el Gini ponderado igual que la figura 9.14; las pruebas reproducen ese ejemplo ($0{,}444 \cdot 6/8 + 0 \cdot 2/8 = 0{,}333$).

El ejemplo 07 con datos reales

Usa los datos de CO2 del caso de estudio: separa 80 % para entrenar y 20 % para probar, ajusta una regresión lineal, un árbol, el perceptrón con sus cuatro activaciones y una red neuronal, y agrupa los países de 2022 con k-medias.

```
# Matrices y aprendizaje automatico con librerias propias (sin NumPy ni scikit-learn)
programa "Matrices y modelos"

# --- Matrices: una matriz es una lista de filas ---
a = [[2, 1], [1, 3]]
mostrar a
mostrar transpuesta(a)
mostrar determinante(a)
mostrar inversa(a)

# sistema de ecuaciones: 2x + y = 5 y x + 3y = 10
mostrar resolver(a, [5, 10])

# --- Datos reales: CO2 de America Latina (Our World in Data) ---
co2 = cargar "datos/co2_latam.csv"
    |> quitar faltantes [gdp, population, co2, co2_per_capita, energy_per_capita]
    |> crear pib_por_persona = gdp / population

# una funcion propia para ponerle nombre al nivel de emisiones
funcion nivel(toneladas) {
    si toneladas > 3 {
        retornar "alto"
    } sino si toneladas > 1.5 {
        retornar "medio"
    }
    retornar "bajo"
}

co2 = co2 |> crear contamina = mapear(nivel, co2_per_capita),
                  contamina_mucho = co2_per_capita > 2
```

```
mostrar correlacion(co2.energy_per_capita, co2.co2_per_capita)

partes = dividir(co2, 0.8)
entrenamiento = partes[0]
prueba = partes[1]

# 1) Prediccion: regresion lineal del CO2 por persona segun la energia y el PIB.
# Es el algoritmo del libro (cap. 3): 5000 epocas de "square trick" con tasa 0.01
lineal = regresion(entrenamiento, ["energy_per_capita", "pib_por_persona"], "co2_per_capita", 0.01,
5000)
mostrar lineal.coeficientes
resultado = predecir(lineal, prueba)
mostrar r2(resultado.co2_per_capita, resultado.prediccion)

# el error cuadratico medio se anota cada lineal.cada epocas
curva_recta = tabla_de({"medicion": rango(longitud(lineal.perdidas)), "error": lineal.perdidas})
graficar lineas de curva_recta {
    eje_x: medicion,
    eje_y: error,
    titulo: "Entrenamiento de la regresion lineal",
    etiqueta_x: "Medicion (cada 25 epocas)",
    etiqueta_y: "Error cuadratico medio",
    archivo: "salidas/perdida_regresion.png"
}

# 2) Clasificacion con un arbol de decision (bajo, medio o alto)
decision = arbol(entrenamiento, ["energy_per_capita", "pib_por_persona"], "contamina", 3)
mostrar reglas(decision)
revision = predecir(decision, prueba)
mostrar exactitud(revision.contamina, revision.prediccion)

# 3) Clasificacion con un perceptron: y = activacion(x1*w1 + x2*w2 + b).
# Se prueban las cuatro activaciones; el escalon usa el "perceptron trick" y las
# otras tres, descenso de gradiente sobre la funcion costo
para activacion en ["escalon", "lineal", "tanh", "sigmoide"] {
    prueba_neurona = perceptron(entrenamiento, ["energy_per_capita", "pib_por_persona"],
                                "contamina_mucho", 0.5, 300, activacion)
    revision = predecir(prueba_neurona, prueba)
    mostrar activacion + ": " + texto(redondear(exactitud(revision.contamina_mucho,
revision.prediccion), 3))
}

neurona = perceptron(entrenamiento, ["energy_per_capita", "pib_por_persona"], "contamina_mucho", 0.5,
300)
mostrar neurona.pesos

# la perdida de cada epoca, para ver que el gradiente si la hizo bajar
curva = tabla_de({"epoca": rango(300), "perdida": neurona.perdidas})
graficar lineas de curva {
    eje_x: epoca,
    eje_y: perdida,
    titulo: "Entrenamiento del perceptron",
    etiqueta_x: "Epoca",
    etiqueta_y: "Entropia cruzada",
    archivo: "salidas/perdida_perceptron.png"
}

# 4) Red neuronal de una capa oculta (retropropagacion) para las tres clases
red = red_neuronal(entrenamiento, ["energy_per_capita", "pib_por_persona"], "contamina", 6, 0.3, 150)
revision = predecir(red, prueba)
mostrar exactitud(revision.contamina, revision.prediccion)

# 5) Agrupamiento: k-medias con los paises en 2022 (el ultimo año con todos los datos)
paises = co2 |> filtrar donde year == 2022
agrupados = grupos(paises, ["co2_per_capita", "energy_per_capita"], 3)
mostrar agrupados |> seleccionar [country, co2_per_capita, energy_per_capita, grupo]
    |> ordenar por [grupo asc, co2_per_capita desc]

graficar dispersion de agrupados {
```

```
    eje_x: energy_per_capita,
    eje_y: co2_per_capita,
    serie: grupo,
    titulo: "Paises agrupados por k-medias (2022)",
    etiqueta_x: "Energia por persona (kWh)",
    etiqueta_y: "CO2 por persona (t)",
    archivo: "salidas/grupos_2022.png"
}
```

Lo que imprime (sin el dibujo del EVA-01):

```
MONITOR a (matriz de 2x2)
  [ 2  1 ]
  [ 1  3 ]

MONITOR (matriz de 2x2)
  [ 2  1 ]
  [ 1  3 ]

MONITOR: 5.0

MONITOR (matriz de 2x2)
  [  0.6  -0.2 ]
  [ -0.2   0.4 ]

MONITOR: [1.0, 3.0]

MONITOR: 0.9449

MONITOR: [0.3966, 0.0002, 0.0]

MONITOR: 0.8776

HOLOGRAM proyectó la gráfica de lineas en salidas/perdida_regresion.png (201 filas)

MONITOR (3 elementos)
  si energy_per_capita <= 6557 -> bajo (115 filas)
  si energy_per_capita > 6557 y energy_per_capita <= 1.544e+04 -> medio (219 filas)
  si energy_per_capita > 1.544e+04 -> alto (143 filas)

MONITOR: 0.7731

MONITOR: escalon: 0.908

MONITOR: lineal: 0.908

MONITOR: tanh: 0.924

MONITOR: sigmoide: 0.924

MONITOR: [4.2854, -0.5763]

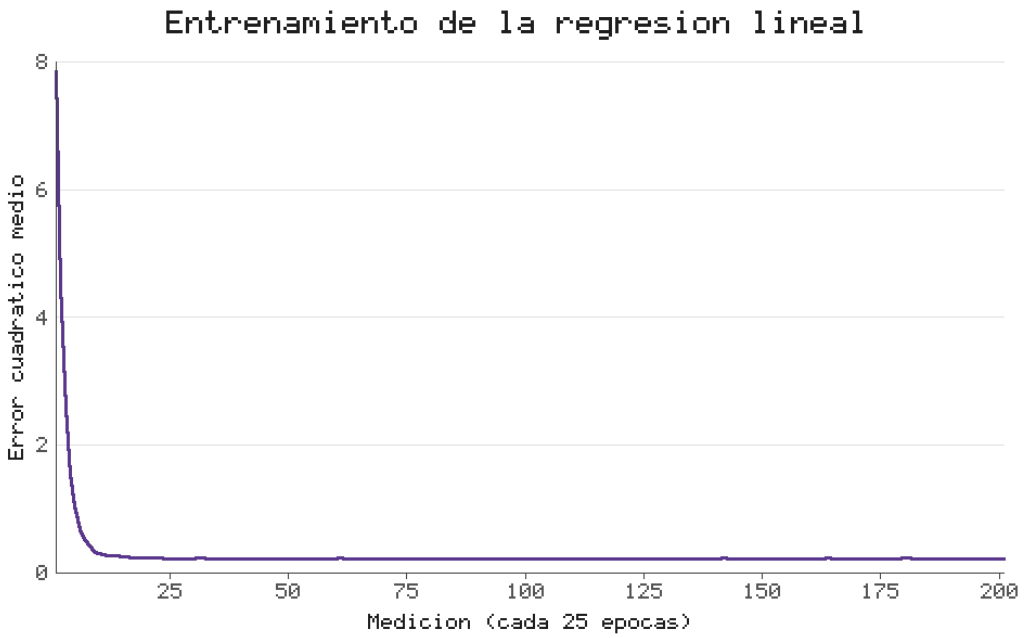
HOLOGRAM proyectó la gráfica de lineas en salidas/perdida_perceptron.png (300 filas)

MONITOR: 0.8319

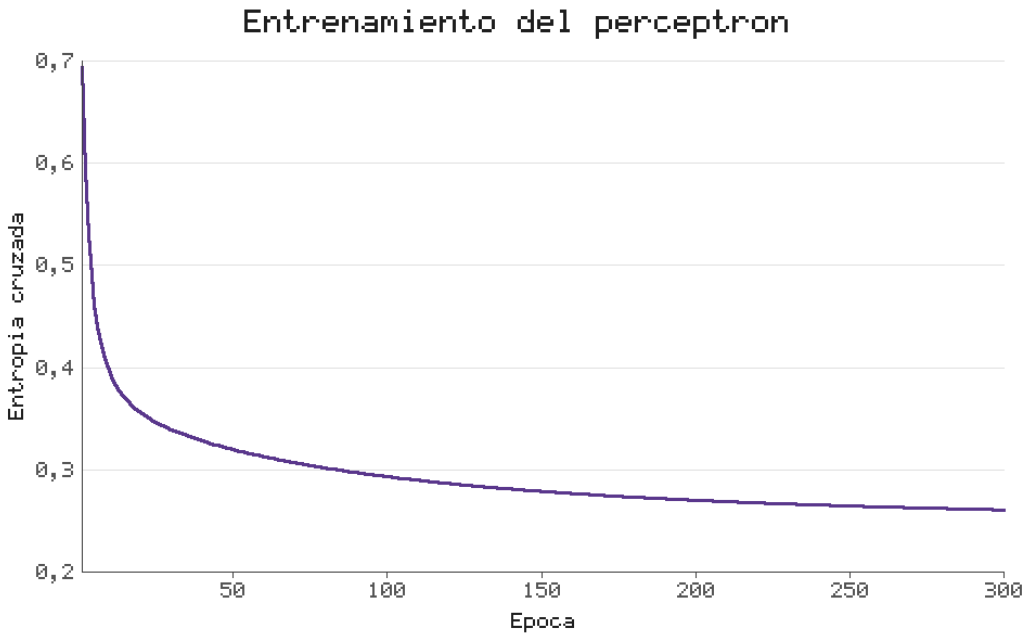
MONITOR (12 filas x 4 columnas)
country     co2_per_capita  energy_per_capita  grupo
Bolivia               1.95            8570.58      1
Peru                  1.94           10099.02      1
Colombia              1.73           12123.15      1
Costa Rica            1.58            9215.24      1
Paraguay              1.11            7732.66      1
Ecuador               2.36           12495.49      2
Brazil                2.28           17744.19      2
Uruguay               2.21           14808.73      2
Chile                 4.38           25750.75      3
Argentina             4.05           22049.94      3
Venezuela             3.84           22898.90      3
```

```
Mexico                3.53          17858.70      3

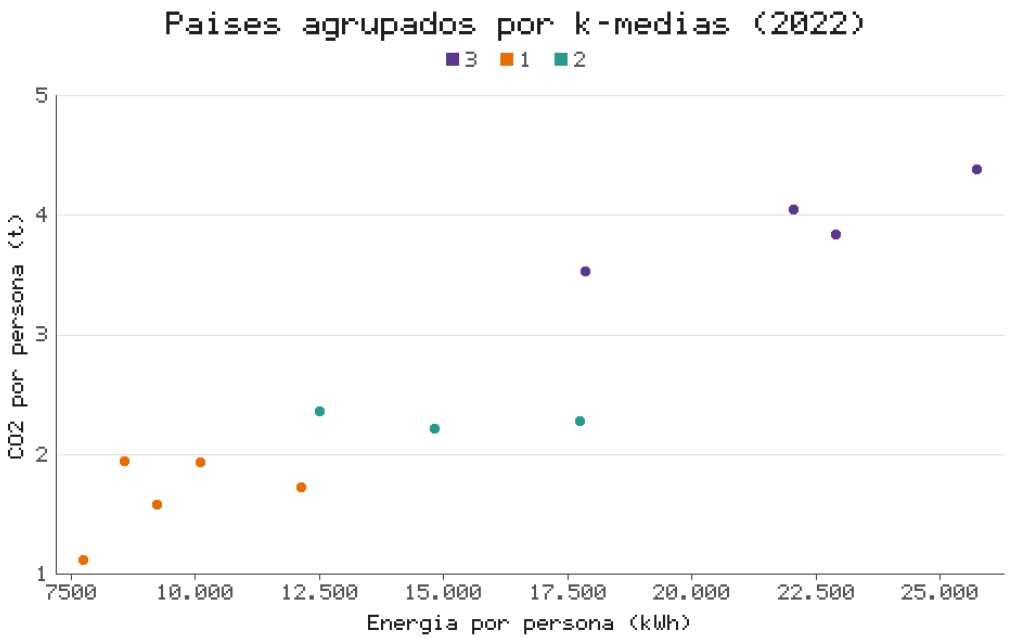
HOLOGRAM proyectó la gráfica de dispersion en salidas/grupos_2022.png (12 filas)
```



El error de la regresión baja a medida que el square trick mueve la recta



Entropía cruzada del perceptrón con sigmoide en cada época



Los 12 países agrupados por k-medias según energía y CO2 por persona

9. Errores

Hay tres clases de error y todas dicen la línea y la columna, muestran la línea de código y ponen una flecha debajo del sitio exacto. Los mensajes de ANTLR vienen en inglés (*mismatched input*…), así que se traducen antes de mostrarlos. Cuando algo falla aparece el comandante Ikari:

```
            .-''''''''''''-.
          .'  ////////////  '.
         /   //////////////   \
        |    .____.  .____.    |
        |  --|####|--|####|--  |
        |    '----'  '----'    |
         \       .----.       /
          \   .-'|_||_|'-.   /
      _____'-/  /|_||_|\  \-'_____
     /      /  / |_||_| \  \      \
    /      /  /   '--'   \  \      \
   /      /  /            \  \      \
  /      /__/              \__\      \
___/_____________________________________\___
```

```
ALERTA: sincronización fallida.
Nivel de contaminación mental alto, el EVA no arranca.

Error sintáctico en sin_01_falta_corchete.eva, línea 4, columna 1
  no se esperaba 'MONITOR'. Aquí debería ir ']' o ','.
      4 | MONITOR pilotos
        | ^

Gendo: "Corrige la línea 4, Shinji. O vete."
```

Un ejemplo de cada clase (sin repetir el dibujo):

Léxico

```
Error léxico en lex_01_caracter_invalido.eva, línea 3, columna 50
  el carácter '@' no pertenece al lenguaje.
      3 | altas = pruebas |> AT_FIELD donde sincronizacion @ 60
        |                                                  ^
```

Sintáctico

```
Error sintáctico en sin_02_etapa_inexistente.eva, línea 3, columna 20
  no se esperaba 'FILTRAR'. Aquí debería ir una etapa (seleccionar, filtrar, crear, agrupar,
resumir... o TARGET, AT_FIELD, SYNC, SQUAD, MAGI...).
      3 | altas = pruebas |> FILTRAR donde sincronizacion > 60
        |                    ^
```

Semántico

```
Error semántico en sem_02_columna_inexistente.eva, línea 3, columna 35
  'sincronisacion' no es una columna de la tabla ni una variable. ¿Quisiste decir 'sincronizacion'?
      3 | altas = pruebas |> AT_FIELD donde sincronisacion > 60
        |                                   ^
```

Semántico

```
Error semántico en sem_03_tipos_incompatibles.eva, línea 3, columna 33
  tipos incompatibles: '*' necesita números y recibió una columna de texto.
      3 | raras = pruebas |> SYNC doble = piloto * 2
        |                                 ^
```

El error semántico solo aparece si el programa está bien escrito: primero se revisan todos los errores léxicos y sintácticos, y la ejecución se detiene en el primer error semántico.

10. Programas completos

En `ejemplos/` hay 7 programas que corren de principio a fin y 15 con errores a propósito. Estos dos muestran el flujo de datos; el 06 y el 07 están en las secciones 6 y 8.

Resumen por piloto

```
# Limpia las pruebas y saca un resumen por piloto
NERV "Resumen por piloto"

pruebas = ENTRY_PLUG "datos/pruebas_sincronizacion.csv"

# Hay una prueba repetida y algunas sin dato
limpias = pruebas
    |> EJECT duplicados
    |> EJECT faltantes [sincronizacion]
    |> DUMMY_PLUG armonicos = 1.0
    |> SYNC indice = redondear(sincronizacion * armonicos, 1),
            apto = sincronizacion >= 40

por_piloto = limpias
    |> SQUAD por [piloto, unidad]
    |> MAGI pruebas = contar(),
            promedio = media(sincronizacion),
            mejor = maximo(sincronizacion),
            peor = minimo(sincronizacion),
            variacion = desviacion(sincronizacion)
    |> FORMATION por [promedio desc]

MONITOR por_piloto
SEELE por_piloto como "salidas/resumen_pilotos.csv"

# Estadisticas de cada columna
MONITOR limpias |> DIAGNOSTIC
```

```
MONITOR por_piloto (5 filas x 7 columnas)
piloto  unidad  pruebas  promedio  mejor   peor  variacion
Kaworu  EVA-02        1     98.00  98.00  98.00       nulo
Shinji  EVA-01        9     67.18  93.50  55.20      12.39
Asuka   EVA-02        8     66.60  92.70  30.30      20.14
Rei     EVA-00       10     56.84  77.90  43.70       9.88
Toji    EVA-03        1     35.20  35.20  35.20       nulo

SEELE recibió el reporte salidas/resumen_pilotos.csv (5 filas)

MONITOR (9 filas x 9 columnas)
columna         clase     validos  faltantes  distintos  media  desviacion  minimo  maximo
prueba          numero         29          0         29  16.14        9.26       1      31
fecha           texto          29          0         10   nulo        nulo    nulo    nulo
piloto          texto          29          0          5   nulo        nulo    nulo    nulo
unidad          texto          29          0          4   nulo        nulo    nulo    nulo
sincronizacion  numero         29          0         29  63.41       16.45   30.30   98.00
armonicos       numero         29          0         24   1.00        0.22    0.62    1.38
bateria_min     numero         29          0          3   4.28        0.88       3       5
indice          numero         29          0         29  62.34       19.93   33.80  119.60
apto            booleano       29          0          2   nulo        nulo    nulo    nulo
```

El archivo `salidas/resumen_pilotos.csv` queda así:

```
piloto,unidad,pruebas,promedio,mejor,peor,variacion
Kaworu,EVA-02,1,98.0,98.0,98.0,
Shinji,EVA-01,9,67.1778,93.5,55.2,12.3947
Asuka,EVA-02,8,66.6,92.7,30.3,20.1384
Rei,EVA-00,10,56.84,77.9,43.7,9.8836
Toji,EVA-03,1,35.2,35.2,35.2,
```

Informe de combates

```
# El archivo de combates viene con ; y con nombres de columna incomodos
NERV "Informe de combates para el comandante"

combates = ENTRY_PLUG "datos/combates.csv" con {
    separador: ";"
```

```
    codificacion: "utf-8"
}
    |> CODENAME [`Angel` -> angel,
                `Episodio` -> episodio,
                `Unidad EVA` -> unidad,
                `Piloto` -> piloto,
                `Duracion (min)` -> minutos,
                `Daño (%)` -> dano,
                `Cable cortado` -> sin_cable]
    |> EQUIP sin_cable -> booleano

# Cuanto daño recibe cada unidad
por_unidad = combates
    |> SQUAD por [unidad]
    |> MAGI combates = contar(),
            dano_medio = media(dano),
            minutos_total = suma(minutos)
    |> FORMATION por [dano_medio desc]

MONITOR por_unidad
SEELE por_unidad como "salidas/dano_por_unidad.csv"

# La bateria interna dura 5 minutos: estos combates fueron los mas apretados
criticos = combates
    |> AT_FIELD donde sin_cable y minutos > 5
    |> SYNC riesgo = redondear(dano * minutos / 100, 2)
    |> TARGET [angel, unidad, piloto, minutos, riesgo]
    |> FORMATION por [riesgo desc]

MONITOR criticos

dano_general = media(combates.dano)
MONITOR dano_general

PATTERN_BLUE dano_general > 40 {
    SEELE criticos como "salidas/combates_criticos.csv"
} PATTERN_ORANGE {
    MONITOR "Sin novedad, las unidades aguantan"
}

# Si no se dice archivo, la grafica queda en salidas/barras_1.png
HOLOGRAM barras de por_unidad {
    eje_x: unidad
    eje_y: dano_medio
    titulo: "Daño promedio por unidad"
    etiqueta_y: "Daño medio (%)"
    color: "rojo"
}
```

```
MONITOR por_unidad (3 filas x 4 columnas)
unidad  combates  dano_medio  minutos_total
EVA-01        10       52.00          74.60
EVA-00         7       47.43          55.80
EVA-02         8       43.62          69.10

SEELE recibió el reporte salidas/dano_por_unidad.csv (3 filas)

MONITOR criticos (6 filas x 5 columnas)
angel       unidad  piloto  minutos  riesgo
Israfel     EVA-01  Shinji    14.00   10.22
Bardiel     EVA-02  Asuka     13.00    9.49
Bardiel     EVA-00  Rei       10.70    6.42
Sandalphon  EVA-02  Asuka      5.40    4.10
Armisael    EVA-00  Rei        6.70    3.95
Zeruel      EVA-00  Rei       11.20    3.70

MONITOR dano_general: 48.04

SEELE recibió el reporte salidas/combates_criticos.csv (6 filas)

HOLOGRAM proyectó la gráfica de barras en salidas/barras_1.png (3 filas)
```

Los datos de `datos/` son de práctica: los nombres salen de la serie y las cifras son inventadas.

11. Caso de estudio: CO2 en América Latina

El caso final usa datos reales de Our World in Data (licencia CC BY 4.0): emisiones de CO2, población y PIB de 12 países de América Latina entre 1970 y 2023, 648 filas. El documento completo, con la descripción de cada columna, las preguntas, la interpretación y los límites, está en `caso_estudio/README.md`. Aquí va el programa y lo que produce.

```
# Caso de estudio de la fase 3: emisiones de CO2 en 12 paises de America Latina.
# Datos reales de Our World in Data (ver caso_estudio/README.md).
# Se corre desde la carpeta del proyecto:  eva caso_estudio\co2_latam.eva
NERV "Emisiones de CO2 en America Latina, 1970-2023"

# --- 1. Carga y limpieza ----------------------------------------------------
co2 = ENTRY_PLUG "datos/co2_latam.csv"
    |> CODENAME [country -> pais, year -> año, population -> poblacion, gdp -> pib,
                co2 -> co2_mt, co2_per_capita -> co2_pc, coal_co2 -> carbon,
                oil_co2 -> petroleo, gas_co2 -> gas, cement_co2 -> cemento,
                energy_per_capita -> energia_pc, share_global_co2 -> parte_mundial]
    |> EJECT columnas [iso_code]
    |> EJECT faltantes [co2_mt, co2_pc]
    |> EJECT duplicados [pais, año]
    |> SYNC pais = reemplazar(pais, "Brazil", "Brasil"),
            pais = reemplazar(pais, "Mexico", "México"),
            pais = reemplazar(pais, "Peru", "Perú"),
            decada = año - año % 10,
            pib_pc = redondear(pib / poblacion, 0)

MONITOR co2 |> DIAGNOSTIC

# --- 2. Indicadores ---------------------------------------------------------
# P1. ¿Quien emitio mas en el ultimo año con datos?
ultimo = co2
    |> AT_FIELD donde año == 2023
    |> TARGET [pais, co2_mt, co2_pc, parte_mundial]
    |> FORMATION por [co2_mt desc]

MONITOR ultimo
SEELE ultimo como "caso_estudio/resultados/emisiones_2023.csv"
```

```
# P2. Promedio y maximo de cada pais en todo el periodo
por_pais = co2
    |> SQUAD por [pais]
    |> MAGI años = contar(),
            co2_pc_medio = media(co2_pc),
            co2_pc_maximo = maximo(co2_pc),
            desviacion_pc = desviacion(co2_pc)
    |> FORMATION por [co2_pc_medio desc]

MONITOR por_pais
SEELE por_pais como "caso_estudio/resultados/resumen_por_pais.csv"

# P3. ¿Colombia esta por encima o por debajo del promedio regional per capita?
colombia = ultimo |> AT_FIELD donde pais == "Colombia"
pc_colombia = media(colombia.co2_pc)
pc_region = redondear(media(ultimo.co2_pc), 3)
MONITOR pc_colombia
MONITOR pc_region

PATTERN_BLUE pc_colombia < pc_region {
    MONITOR "Colombia emite menos CO2 por persona que el promedio de los 12 paises"
} PATTERN_ORANGE {
    MONITOR "Colombia emite mas CO2 por persona que el promedio de los 12 paises"
}

# --- 3. Graficas ------------------------------------------------------------
# G1. Barras: emisiones totales de 2023
HOLOGRAM barras de ultimo {
    eje_x: pais
    eje_y: co2_mt
    titulo: "Emisiones de CO2 en 2023"
    etiqueta_x: "País"
    etiqueta_y: "Millones de toneladas de CO2"
    archivo: "caso_estudio/resultados/g1_barras_emisiones_2023.png"
}

# G2. Lineas: como cambio el CO2 por persona en los seis que mas emiten
grandes = co2
    |> AT_FIELD donde pais == "Brasil" o pais == "México" o pais == "Argentina"
                  o pais == "Venezuela" o pais == "Colombia" o pais == "Chile"

HOLOGRAM lineas de grandes {
    eje_x: año
    eje_y: co2_pc
    serie: pais
    titulo: "CO2 por persona, 1970-2023"
    etiqueta_x: "Año"
    etiqueta_y: "Toneladas por persona"
    archivo: "caso_estudio/resultados/g2_lineas_co2_por_persona.png"
}

# G3. Histograma: como se reparten los valores de todos los paises y años
HOLOGRAM histograma de co2 {
    eje_x: co2_pc
    intervalos: 16
    titulo: "Distribución del CO2 por persona (12 países, 1970-2023)"
    etiqueta_x: "Toneladas por persona"
    etiqueta_y: "Cantidad de país-año"
    color: "verde"
    archivo: "caso_estudio/resultados/g3_histograma_co2_por_persona.png"
}

# G4. Dispersion: ¿los paises mas ricos emiten mas por persona?
desde_2000 = co2
    |> AT_FIELD donde año >= 2000 y pib != nulo
    |> SYNC pib_pc_miles = pib_pc / 1000

HOLOGRAM dispersion de desde_2000 {
    eje_x: pib_pc_miles
```

```
    eje_y: co2_pc
    serie: pais
    titulo: "Riqueza contra emisiones, 2000-2022"
    etiqueta_x: "PIB por persona (miles de dólares de 2011)"
    etiqueta_y: "Toneladas de CO2 por persona"
    archivo: "caso_estudio/resultados/g4_dispersion_pib_vs_co2.png"
}

# G5. Caja: como cambio la diferencia entre paises de una decada a otra
HOLOGRAM caja de co2 {
    eje_x: decada
    eje_y: co2_pc
    titulo: "CO2 por persona por década"
    etiqueta_x: "Década"
    etiqueta_y: "Toneladas por persona"
    color: "morado"
    archivo: "caso_estudio/resultados/g5_caja_por_decada.png"
}

# La misma grafica de lineas tambien sale en SVG, que se ve nitida a cualquier tamaño
HOLOGRAM lineas de grandes {
    eje_x: año
    eje_y: co2_pc
    serie: pais
    titulo: "CO2 por persona, 1970-2023"
    etiqueta_x: "Año"
    etiqueta_y: "Toneladas por persona"
    archivo: "caso_estudio/resultados/g2_lineas_co2_por_persona.svg"
}
```

Lo que imprime (sin el dibujo del EVA-01):

```
MONITOR (14 filas x 9 columnas)
columna        clase   validos  faltantes  distintos            media       desviacion      minimo
maximo
pais           texto       648          0         12              nulo              nulo        nulo
nulo
año            numero      648          0         54          1996.50            15.60        1970
2023
poblacion      numero      648          0        648      34817180.73      46691526.13     1838946
211140731
pib            numero      636         12        636  390536571710.22  596265426527.80  6996917376
3187412907763
co2_mt         numero      648          0        643            92.24           126.58        0.63
556.53
co2_pc         numero      648          0        596             2.32             1.44        0.26
6.63
carbon         numero      503        145        384            10.62            16.04        0.00
69.45
petroleo       numero      648          0        636            57.78            80.15        0.60
356.75
gas            numero      512        136        476            24.78            34.17        0.00
172.08
cemento        numero      648          0        575             3.54             5.27        0.02
25.80
energia_pc     numero      608         40        608         12217.73          7572.25     1977.54
35695.15
parte_mundial  numero      648          0        352             0.35             0.44        0.00
1.62
... y 2 filas más

MONITOR ultimo (12 filas x 4 columnas)
pais        co2_mt  co2_pc  parte_mundial
Brasil      483.99    2.29           1.27
México      458.25    3.53           1.20
Argentina   178.41    3.92           0.47
Venezuela   119.59    4.23           0.31
Colombia     89.99    1.72           0.24
Chile        77.60    3.95           0.20
```

```
Perú         66.06    1.95           0.17
Ecuador      44.60    2.48           0.12
Bolivia      24.62    2.01           0.07
Costa Rica    8.47    1.66           0.02
Paraguay      7.65    1.12           0.02
Uruguay       7.63    2.25           0.02

SEELE recibió el reporte caso_estudio/resultados/emisiones_2023.csv (12 filas)

MONITOR por_pais (12 filas x 5 columnas)
pais        años  co2_pc_medio  co2_pc_maximo  desviacion_pc
Venezuela     54          5.37           6.63           0.81
Argentina     54          3.87           4.64           0.37
México        54          3.74           4.42           0.52
Chile         54          3.19           4.79           1.01
Ecuador       54          1.87           2.73           0.54
Uruguay       54          1.81           2.58           0.37
Brasil        54          1.81           2.78           0.46
Colombia      54          1.66           2.03           0.18
Perú          54          1.29           1.95           0.28
Costa Rica    54          1.28           1.80           0.32
Bolivia       54          1.21           2.01           0.45
Paraguay      54          0.70           1.32           0.28

SEELE recibió el reporte caso_estudio/resultados/resumen_por_pais.csv (12 filas)

MONITOR pc_colombia: 1.72

MONITOR pc_region: 2.592

MONITOR: Colombia emite menos CO2 por persona que el promedio de los 12 paises

HOLOGRAM proyectó la gráfica de barras en caso_estudio/resultados/g1_barras_emisiones_2023.png (12
filas)

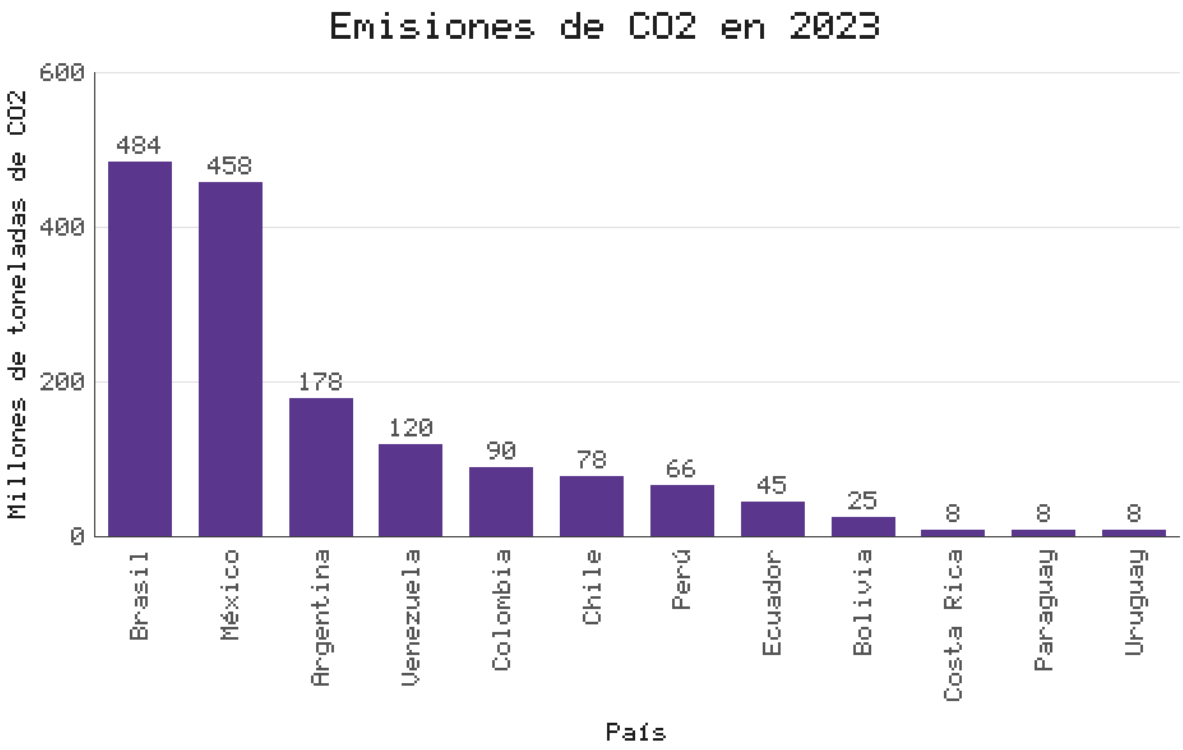
HOLOGRAM proyectó la gráfica de lineas en caso_estudio/resultados/g2_lineas_co2_por_persona.png (324
filas)

HOLOGRAM proyectó la gráfica de histograma en caso_estudio/resultados/g3_histograma_co2_por_persona.png
(648 filas)

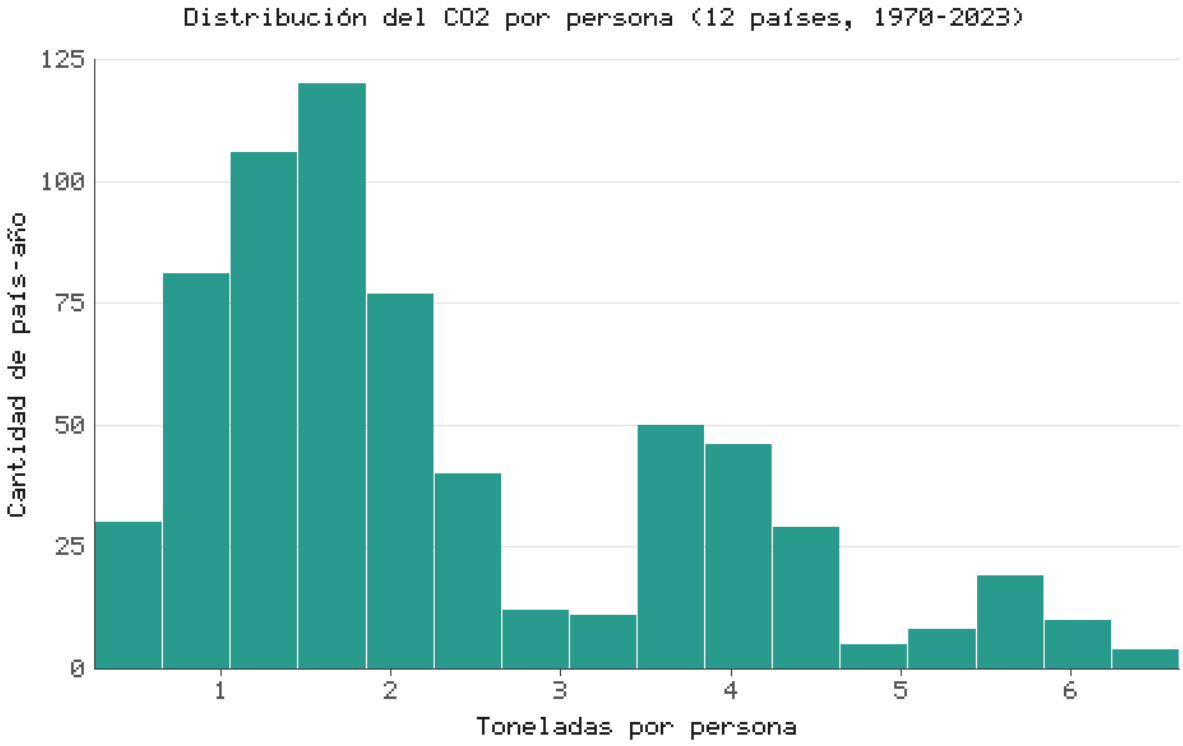
HOLOGRAM proyectó la gráfica de dispersion en caso_estudio/resultados/g4_dispersion_pib_vs_co2.png (276
filas)

HOLOGRAM proyectó la gráfica de caja en caso_estudio/resultados/g5_caja_por_decada.png (648 filas)

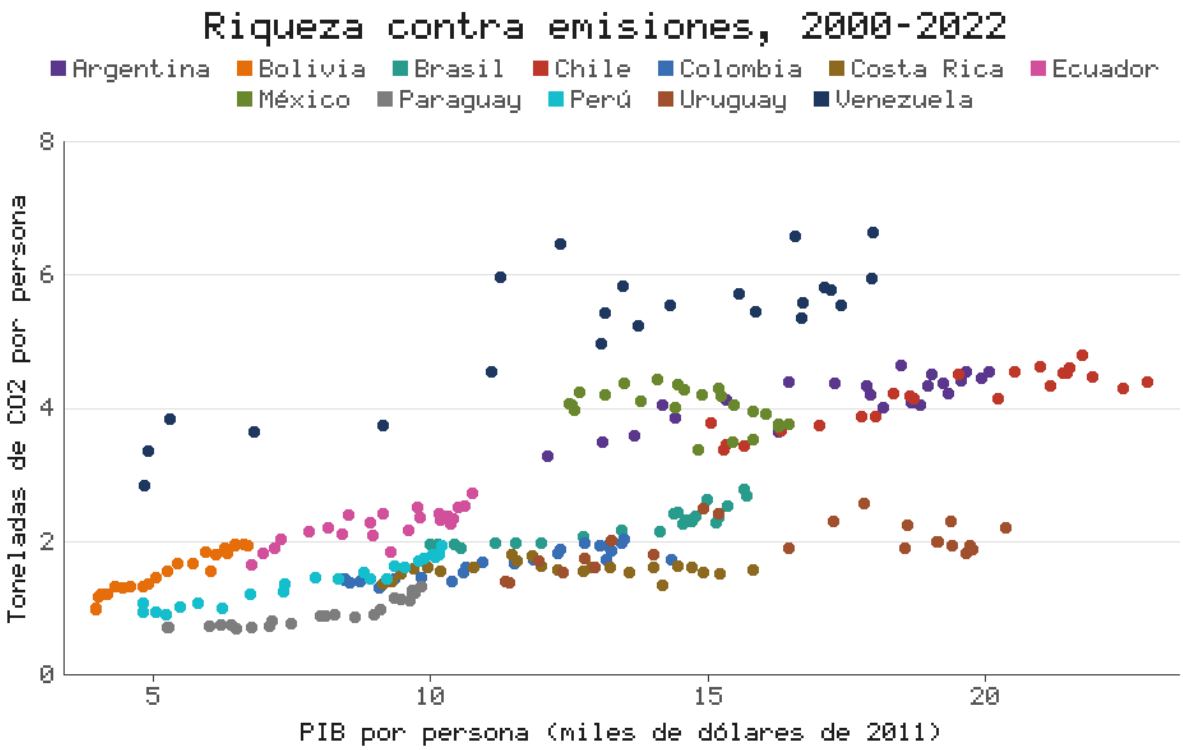
HOLOGRAM proyectó la gráfica de lineas en caso_estudio/resultados/g2_lineas_co2_por_persona.svg (324
filas)
```



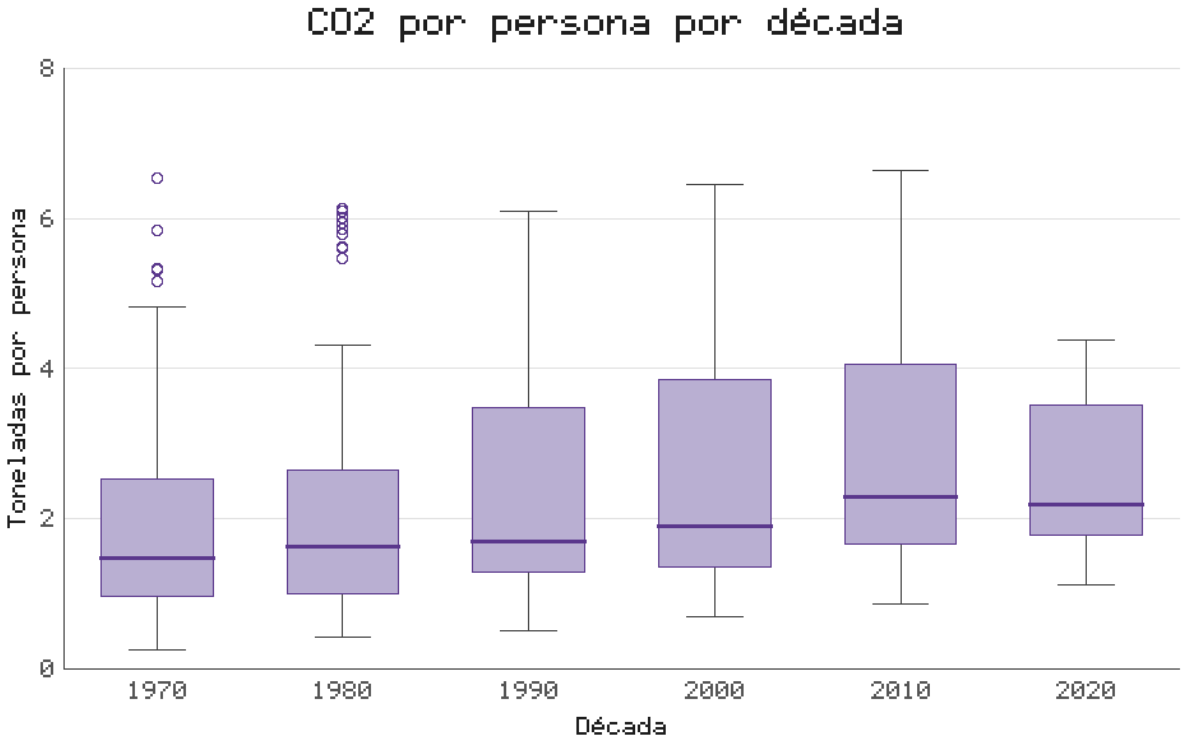
G1. Barras: emisiones totales de 2023



G3. Histograma del CO2 por persona



G4. Dispersión: PIB por persona contra CO2 por persona



G5. Caja: CO2 por persona en cada década

Qué muestran

Brasil y México emitieron en 2023 el 60 % del CO2 de los 12 países, pero por persona los que más emiten son Venezuela, Chile y Argentina. Toda la región está por debajo del promedio mundial (4,71 t por persona). Colombia emite 1,72 t por persona, por debajo del promedio regional de 2,59

t, y es el país con la serie más estable. Hay una relación clara entre PIB por persona y CO2 por persona, con Uruguay y Costa Rica como excepción. La mediana regional subió de 1,48 t en los años 70 a 2,19 t en los 2020.

12. Cómo se usa

```
python -m venv .venv                          (crea el entorno, una sola vez)
pip install antlr4-python3-runtime==4.13.2 pytest
python run.py ejemplos/01_primera_prueba.eva   (ejecuta un programa)

python run.py programa.eva --tokens           (muestra los tokens)
python run.py programa.eva --arbol            (muestra el árbol en texto)
python run.py programa.eva --svg arbol.svg    (guarda el árbol como dibujo)
python run.py programa.eva --simbolos         (muestra la tabla de símbolos)
python run.py programa.eva --solo-analisis    (fase 1 sin ejecutar)

python -m pytest                              (corre las pruebas)
python regenerar.py                           (vuelve a generar lexer y parser)
```

Las rutas de los CSV se leen desde la carpeta donde se ejecuta el comando, por eso los ejemplos se corren parados en la raíz del proyecto.

Carpeta	Contenido
`grammar/`	`Eva.g4`, la gramática de ANTLR con las reglas léxicas y sintácticas juntas.
`src/evangelion/`	El analizador (fase 1), el intérprete, la tabla de símbolos y la librería de tablas (fase 2), las gráficas, el lienzo y la letra de píxeles (fase 3), las librerías de matemáticas, matrices y aprendizaje automático, los errores, el árbol y los dibujos de la terminal.
`src/evangelion/generado/`	Lo que genera ANTLR. No se edita a mano.
`ejemplos/`	Programas válidos y, en `errores/`, programas que deben fallar.
`datos/`, `salidas/`	Los CSV de entrada y los reportes y gráficas que escriben los ejemplos.
`caso_estudio/`	El caso final: programa, documento, script de descarga y resultados.
`tests/`	Pruebas con pytest de las tres fases.

13. Reporte de pruebas

Las pruebas están en `tests/` y se corren con `python -m pytest`. Las de las fases 1 y 2 se siguen corriendo, así que sirven de pruebas de regresión: si algo de la fase 3 hubiera dañado lo de antes, fallarían. Resultado al generar este manual:

Archivo	Qué revisa	Pruebas
`test_fase1.py`	Tokens, precedencia, forma del árbol, errores léxicos y sintácticos con línea y columna.	58
`test_fase2.py`	Cada etapa del flujo, expresiones, tabla de símbolos, errores semánticos y los ejemplos de punta a punta.	95

Archivo	Qué revisa	Pruebas
`test_fase3.py`	Compresor, CRC y PNG contra la librería estándar, la letra, escalas y cuartiles, los cinco tipos en PNG y SVG, las opciones y errores de HOLOGRAM y el caso de estudio completo.	37
`test_lenguaje.py`	Palabras en español, ciclos, funciones, listas y diccionarios, casos borde, las matemáticas propias contra math de Python, matrices, y cada modelo con casos de respuesta conocida (una recta exacta, XOR, el Gini de la figura 9.14 del libro, el gradiente contra la derivada numérica).	110
`test_tablas.py`	La librería de tablas por separado: CSV, columnas, estadísticas y operaciones de tabla.	26
Total		**326**

```
$ python -m pytest
326 passed in 17.07s
```

Límites conocidos

No hay uniones entre tablas (joins). Las funciones no se pueden pasar sin nombre (no hay lambdas) y las variables de los ciclos quedan definidas después del ciclo. Tampoco se puede pasar una tabla de formato ancho a largo, por eso una gráfica con varias series necesita una columna que diga a qué serie pertenece cada fila. El PNG usa paleta, que admite hasta 256 colores, y la letra de píxeles no lleva tilde en las mayúsculas. Los modelos entrenan con descenso de gradiente en Python puro, así que con decenas de miles de filas se demoran; para el tamaño de los datos del curso tardan pocos segundos.